程设第二次作业 20377383 樊思涵

前言:看了同学们的展示作业,意识到自己的作业有很多不足,这次作业决定学习展示作业中函数注释的写法,改变代码风格。

任务 1.

准备活动:

调用的库:

```
import numpy as np
import jieba
import re
from matplotlib import pyplot as plt
```

将需要用到的文件地址作为全局变量

```
#文件名用作全局变量
filename_0=r'C:\Users\LF\Desktop\weibo.txt\weibo.txt'
filename_0_test=r'C:\Users\LF\Desktop\weibo.txt\test_weibo.txt'
filename_anger=r'C:\Users\LF\Desktop\emotion_lexicon\anger.txt'
filename_disgust=r'C:\Users\LF\Desktop\emotion_lexicon\disgust.txt'
filename_fear=r'C:\Users\LF\Desktop\emotion_lexicon\fear.txt'
filename_joy=r'C:\Users\LF\Desktop\emotion_lexicon\joy.txt'
filename_sadness=r'C:\Users\LF\Desktop\emotion_lexicon\sadness.txt'
filename_emotions=[filename_anger,filename_disgust,filename_fear,filename_joy,filename_sadness]
```

补充:

```
15 EMO=['anger','disgust','fear','joy','sadness']
16 TIMEMODE=['week','hour','month']
```

其中,test_weibo.txt 为 473 条小样本量测试用微博数据 按行读入文件

```
def fread document(filename) -> list:
17
       按行读入txt文件并返回列表
       ->返回一维列表
       :filename:原始文档目录
20
       print("-------正在导入数据-----")
21
       f=open(filename,encoding='UTF-8')
       line = f.readline().strip() #读取第一行,不用读入列表
       txt=[]
       while line: # 直到读取完文件
           line = f.readline().strip() # 读取一行文件,包括换行符
           txt.append(line)
       f.close() # 关闭文件
       if txt[-1]==":
           txt.pop()
       print("-----数据导入完成------")
       return txt
```

处理重复微博

展示结果

```
PS E:\code\py_code> python -u "e:\code\py_code\week3\week3.py"
------正在导入数据-------
-----数据导入完成-------
有重复微博
处理前数据有2422485项。
处理重复数据后有272883项。
------正在添加情绪词------
```

没想到这么多重复数据!

对数据进行分割降噪处理 Step1.对\t 分割,得到 column = 4 的列表

Step2.删除每条微博后都有的"我在这里: xxxxx"

```
      58
      def fdelete_url_data(data,n) -> list:

      59
      """

      60
      删除每条微博后相同的url地址

      61
      ->返回与data相同的column=4的二位列表

      62
      :data:切割於的二维列表

      63
      :n:二维列表长度

      64
      """

      65
      sentence=[] #专门用来储存微博内容

      66
      #根据字符串格式切割

      67
      for i in range(n):

      68
      #print(data[i][1])

      69
      sentence.append(data[i][1].rsplit(' ',1)[0])

      70
      ##print(sentence)

      71
      return sentence
```

Step3.使用正则表达式删除一些无意义的文本

```
| def fclean_sentence(sentence,n) -> list:
| """ | 使用正则表达式对文本路達
| ->返回与sentence相同的一维列表
| sentence:
| sentence:
| in:列表长度
| "" | for i in range(n):
| sentence[i] = re.sub(r"(回复)?(//?\s*@\S*?\s*(:| [$)"," ",sentence[i]) # 去除正文中的岭和回复/转发中的用户名
| sentence[i] = re.sub(r"(S]+\.(cn|net|com|org|info|edu|gov|uk|de|ca|jp|fr|au|us|ru|ch|it|nel|se|no|es|mil)[\S]*\s?','',sentence[i])# 去除网址
| sentence[i] = re.sub(r"\s+", " ", sentence[i]) # 合并正文中过多的空格
| return sentence
```

过滤效果如下:

分析:在删除无意义文本时,不能删除所有的表情,因为在情绪分词中记录了表情,不同表情显然能够表达不同的情绪。

任务 2.

在分词表中添加情绪词

创建闭包函数 取出现次数最多的 emotion 为对应微博的情绪

```
def fdic_emotion(filename_emotions,data,sentence,n):
        闭包函数返回情绪,时间,地址列表函数
        ->函数名
        :filename_emotions:情绪地址列表
        :data:column=4的全信息列表
        :sentence:处理后的文本字符
        :n:列表长度
103
        emodict = []
        for i in filename_emotions:
           file = open(i,'r',encoding='utf-8')
           emodict.append([line.strip() for line in file.readlines()])
           file.close()
        def splitword(): #分词获取情绪以及对应的时间地点
           nonlocal emodict
           emotion_list,time_list,address_list = [],[],[]
           for i in range(n):
               emotion_dict = {'anger':0,'disgust':0,'fear':0,'joy':0,'sadness':0}
               splitword = jieba.lcut(sentence[i])
```

```
for word in splitword:
117 ~
118 ~
                     if word in emodict[0]:
                          emotion_dict['anger']+=1
119
120 ~
                     elif word in emodict[1]:
121
                          emotion_dict['disgust']+=1
122 \
                     elif word in emodict[2]:
                          emotion_dict['fear']+=1
123
124 ~
                     elif word in emodict[3]:
125
                          emotion_dict['joy'] +=1
126 ~
                     elif word in emodict[4]:
                          emotion_dict['sadness']+=1
                 if max(emotion_dict.values())==0:
128 ~
                     emotion = 'none'
129
130 ~
                 else:
                     emotion = max(emotion_dict,key=emotion_dict.get)
                 emotion_list.append(emotion)
133
                 time_list.append(data[i][3])
134
                 address_list.append(data[i][0])
             print(emotion_list,end = '')
135
136
             return emotion_list,time_list,address_list
137
         return splitword
138
```

结果展示 (用测试数据文本)

Emotion list

```
PVPTIX DICT has been foult successfully.

(none) sadness, 'anger' joy 'none', 'soy', 'joy', 'none', 'sadness, 'none', 'joy', 'sadness, 'four', 'none', 'sadness, 'joy', 'none', 'sadness, 'joy', 'none', 'soy', 'joy', 'sadness, 'joy', 'none', 'joy', 'joy', 'sadness, 'joy', 'none', 'joy', 'joy', 'sadness, 'joy', 'none', 'joy', 'joy', 'soy', 'soy',
```

time list

[Fri Oct 11 22:08:28 40000 2013, 'Fri Oct 11 23:38:140 40000 2013, 'Fri Oct 11 23:28:44 40000 2013, 'Fri Oct 11 23:28:40 40000 2013, 'Fri Oct 11 23:28:28 40000 2013,

address list

[136.7884, 16.19924], [136.78874, 116.12548], [23.07922, 116.29921], [23.688278, 116.31194], [23.67278, 116.39926], [23.688278, 116.11578], [23.688278, 116.31924], [23.688278, 116.31924], [23.688278, 116.31924], [23.688278, 116.48928], [23.688278, 116.48928], [23.688278, 116.48928], [23.688278, 116.48928], [23.688278, 116.48928], [23.688278, 116.48928], [23.688278, 116.48928], [23.688278, 116.48928], [23.688278, 116.48928], [23.688278, 116.48928], [23.68828, 116.48928], [23.688

任务 3.

创建小时、星期、月份字典,统计每条的属性

```
154 > def fplotime(emotion,time_mode,emotion_list,time_list):
155 > """
156 生成指定情绪指定模式的情绪统计图
157 :emotion:目标的情绪的字符串
158 :time_mode:目标的时间图表模式
159 :emotion_list:微博情绪列表
160 :time_list:微博时间列表
161 """
162 week = ['Mon','Tue','Wed','Thu','Fri','Sat','Sun']
163 week_dict = {}
164 week_dict = week_dict.fromkeys(week,0)
165
166 month = ['Jan','Feb','Mar','Apr','May','Jun','Jul','Aug','Sep','Oct','Nov','Dec']
167 month_dict = {}
168 month_dict = month_dict.fromkeys(month,0)
169
170 hour = ['{:0>2d}'.format(i) for i in range(24)]
171 hour_dict = {}
172 hour_dict = hour_dict.fromkeys(hour,0)
```

对三种不同模式进行计数(仅仅贴出 week 代码)


```
174
         if time mode == 'week':
175
             for tm in time_list:
                 if emotion_list[time_list.index(tm)] == emotion:
177
                     week_dict[tm[0]] += 1
178
            week_value = []
179
             for value in week_dict.values():
180
                 week_value.append(value)
             plt.plot(week,week_value,'o-',color='r',label='week_{}'.format(emotion))
             plt.xlabel("week")#横坐标名字
            plt.ylabel("times")#纵坐标名字
            plt.legend(loc = "best")#图例
185
             for a,b in zip(week,week_value):
186
                 plt.text(a,b+1,b,ha = 'center',va = 'bottom',fontsize=10)
187
            #print(week_dict)
```

输出并保存图像


```
plt.savefig('{}_{}.png'.format(time_mode,emotion),dpi=800)

#plt.show()
```


一共输出 15 张图



举例分析 1:



观察 24 小时内的悲伤情绪图,发现 22.23 点的悲伤微博数明显多于其他时间的微博数,考虑到经常有人在晚上"深夜 emo",该图像很好地证明了这一点。凌晨由于发微博人数问题导致数据较低也属于正常现象。 举例分析 2:




观察周一到周五的心情,周六和周日明显高于工作日,而周一是工作日的第一天,相应的数据也近似最低,

任务 6.


提取每条微博的地点坐标, 并画出散点图

```
221 v def emotion admode(address list,emotion list,n):
222 ~
223
         画出位置分布图
          :address list:微博地址列表
          :emotion list:微博情绪列表
225
          :n:列表长度
226
228
         x list=[]
229
         y list=[]
         add emotion = []
230
231
         color_list = ['red', 'green', 'purple', 'yellow', 'blue']
          for i in range(n):
232 ~
233
              zuobiao = address_list[i].split(',')
234
             x list.append(float(zuobiao[0][1:]))
             y list.append(float(zuobiao[1][:-1]))
236
              add emotion.append(emotion list[i])
          for i in range(5):
237 ~
238
             x=[]
239
             y=[]
              for j in range(n):
                  if EMO[i] == add emotion[j]:
242
                      x.append(x list[j])
                      y.append(y list[j])
             plt.scatter(x,y, c = color list[i])
             plt.title('The Space Mode of ' + EMO[i])
             plt.show()
246
```

读入全部的数据



发现明显分成了四类,可以用肉眼聚类分析得知分成四个部分,需要将不同地区的数据分别分析才能得到有价值的信息。 通过筛选特定部分的微博获得同类的数据,再次进行可视化分析:



观察发现情绪为 joy 的微博有一定的聚集效应,如图中的右侧明显更为集中,这一现象可能与情绪的传染性有关,值得进一步研究。

Main 函数如下:

```
def main():
250
        main函数
        txt=fread document(filename 0 test) #读取txt文件
252
        m=len(txt)
254
         txt=fdelete repetition txt(txt) #删除重复项
         n=len(txt) #记录项数
        print("处理前数据有%d项.\n处理重复数据后有%d项."%(m,n))
256
        data=fcut txt(txt,n) #简单切割内容、地址、时间
        n=len(data)#更新项数
        print(n)
         sentence = fdelete url data(data,n) #简单分词处理
         sentence = fclean sentence(sentence,n) #正则表达式降噪
         #faddword(filename emotions) #添加情绪词
         f=fdic emotion(filename emotions,data,sentence,n)
         emotion list, time list, address list = f()
         time list new=ftime list(time list,n)
         for emotion in EMO:
             for timemode in TIMEMODE:
                fplotime(emotion, timemode, emotion list, time list new)
270
         emotion admode(address list,emotion list,n)
271
272
     if __name__ == '__main__':
        main()
```

Ref:

逐行读取 txt 文件

https://cloud.tencent.com/developer/article/2080154

学习正则表达式

https://blog.csdn.net/weixin 42550871/article/details/108943529

https://blog.csdn.net/bang152101/article/details/89284249

使用正则表达式切除 url 和域名

https://www.lmlphp.com/user/151450/article/item/8191109/